

# ComProScanner

从 PDF、API 文献发现到材料—性质数据库的完整技术报告

原论文中文精读 | 当前 Tc 改造 | 目录与逐文件职责 | 数据路径 | 评测与扩展

项目位置: F:\Python\_Project\ComProScanner

分支: magnetic-scientific-facts

报告快照: 2026-08-29 (Asia/Shanghai)

阅读目标: 读完后应能亲自解释输入文件放在哪里、每一步由哪个模块负责、数据为何可能漏掉、JSON 与数据库在哪里, 以及如何用最小改动增加 Ms 等新性质。

# 阅读说明与结论先行

这是一份面向项目维护者的“地图”，不是仅面向使用者的 README。报告同时区分原始开源框架、已经冻结的 Tc 版本、当前尚未冻结的 Hybrid+Qwen 实验，避免把论文能力、代码中存在的能力和当前实际启用的能力混为一谈。

## 你应先记住的七件事

- ComProScanner 的核心单位不是整篇 PDF，而是“论文 → 规范化章节 CSV → 候选上下文 → 结构化事实”。
- 本地 PDF 与出版社/API 获取的全文在入口不同，进入规范化章节表以后会汇合到同一抽取主干。
- DOI 主要承担身份、元数据关联、去重和向量库命名；没有 DOI 并不应阻止本地 PDF 抽取。
- Tc 适配主要由 preset 和候选策略完成，没有复制整套抽取框架；当前模型分工是 Qwen 做低成本判定，DeepSeek 做材料—Tc 抽取。
- PhysBERT/Chroma 是候选补充手段，不是最终抽取模型；当前 hybrid 规则要求它只能追加，失败时退回规则候选。
- 图像抽取与图表 VLM 工具在仓库中存在，但当前 Tc 批处理显式关闭了相关图保存和图像读取，因此现有 Tc 指标是文本链路指标。
- 最终可审计资产是逐篇 prediction、合并 prediction、人工接受 Gold 和 metrics；work/db/log/tmp 是可再生中间物。

## 当前可量化状态

| 项目                      | 快照值                                                 | 解释                                    |
|-------------------------|-----------------------------------------------------|---------------------------------------|
| 前 30 篇 strict Gold      | 46                                                  | 另有 1 条 Paper 30 范围事实作为 non-strict 保留  |
| TP / FP / FN            | 42 / 1 / 4                                          | 按 hybrid+Qwen 当前严格口径                  |
| Precision / Recall / F1 | 0.977 / 0.913 / 0.944                               | 不是早期 9 篇 Dev 的 1.000 指标               |
| Paper 1–100 批处理         | 已落盘至 Paper 78                                       | 报告生成时动态快照；未完批次不得当作最终评测                |
| 落盘状态分布                  | COMPLETED=45; EMPTY_RESULT=9; PREFILTER_REJECTED=24 | COMPLETED 表示有价值；EMPTY_RESULT 也是一次正常完成 |

# 目录

可从 PDF 书签直接跳转。本报告先解释原论文，再解释当前工程；最后给出逐文件索引、运行手册、问题清单与汇报提纲。

|                                |           |
|--------------------------------|-----------|
| <b>阅读说明与结论先行</b>               | <b>2</b>  |
| 你应先记住的七件事                      | 2         |
| 当前可量化状态                        | 2         |
| <b>目录</b>                      | <b>3</b>  |
| <b>1. 原论文：它解决了什么问题</b>         | <b>5</b>  |
| 1.1 论文信息                       | 5         |
| 1.2 为什么需要它                     | 5         |
| 1.3 论文四阶段                      | 5         |
| 1.4 五个 agent 与工具               | 6         |
| 1.5 论文实验与结论的中文精读               | 7         |
| <b>2. 原始框架与当前项目：哪些没变，哪些改变了</b> | <b>7</b>  |
| 2.1 Git 演进节点                   | 8         |
| <b>3. 总体架构：四层如何配合</b>          | <b>8</b>  |
| <b>4. 路径 A：你手动放入 PDF 后发生什么</b> | <b>8</b>  |
| 4.1 文件选择与编号                    | 8         |
| 4.2 PDFsProcessor              | 9         |
| 4.3 Docling 解析                 | 9         |
| 4.4 规范化章节 CSV                  | 9         |
| 4.5 原始文本恢复                     | 9         |
| 4.6 输出落点                       | 9         |
| <b>5. 路径 B：API 发现与下载 PDF</b>   | <b>9</b>  |
| 5.1 推荐的发现流程                    | 9         |
| 5.2 API 各自负责什么                 | 10        |
| 5.3 无 Semantic Scholar key 时   | 10        |
| <b>6. DOI 在项目中的真实作用</b>        | <b>10</b> |
| <b>7. 候选文本如何产生，以及为何会丢上下文</b>   | <b>10</b> |
| 7.1 SectionProcessor 的规则候选     | 10        |
| 7.2 论文级预筛                      | 11        |
| 7.3 Hybrid PhysBERT            | 11        |
| 7.4 上下文仍可能缺失的四处                | 11        |
| <b>8. Tc 抽取的实际模型链路</b>         | <b>11</b> |
| 8.1 Tc 的科学边界                   | 11        |
| 8.2 状态语义                       | 12        |

|                                        |           |
|----------------------------------------|-----------|
| <b>9. JSON、Gold、评分与“数据库”</b>           | <b>12</b> |
| 9.1 单篇 prediction 结构 . . . . .         | 12        |
| 9.2 四种存储后端 . . . . .                   | 12        |
| 9.3 Gold 与指标 . . . . .                 | 12        |
| <b>10. 当前 30 篇的错误分析</b>                | <b>13</b> |
| 10.1 调试顺序 . . . . .                    | 13        |
| <b>11. 项目目录总览</b>                      | <b>13</b> |
| <b>12. 逐文件职责：公共入口、处理器与元数据</b>          | <b>14</b> |
| <b>13. 逐文件职责：抽取 flow、crews 与工具</b>     | <b>14</b> |
| <b>14. 逐文件职责：utils 与配置</b>             | <b>14</b> |
| <b>15. 逐文件职责：preset、后处理、runner 与测试</b> | <b>15</b> |
| <b>16. 一次运行的调用栈与伪代码</b>                | <b>16</b> |
| 16.1 为什么单篇失败不停止 . . . . .              | 16        |
| <b>17. 图片、表格与视觉模型：代码存在 ≠ 当前启用</b>      | <b>16</b> |
| <b>18. 增加 Ms 等新性质的最小改动方案</b>           | <b>16</b> |
| 18.1 Ms preset 应包含 . . . . .           | 17        |
| 18.2 何时需要扩 schema . . . . .            | 17        |
| <b>19. 当前架构中不干净或不合理的地方</b>             | <b>17</b> |
| <b>20. 安全、成本与可复现运行规范</b>               | <b>17</b> |
| <b>21. 你可以亲自执行的操作手册</b>                | <b>18</b> |
| 21.1 检查输入映射 . . . . .                  | 18        |
| 21.2 运行指定论文 . . . . .                  | 18        |
| 21.3 恢复批次 . . . . .                    | 18        |
| 21.4 查看进度 . . . . .                    | 18        |
| 21.5 调试一条 FN . . . . .                 | 18        |
| <b>22. 明日汇报可直接使用的 10 分钟提纲</b>          | <b>18</b> |
| <b>23. 术语表</b>                         | <b>18</b> |
| <b>24. 参考资料与本地证据</b>                   | <b>19</b> |

# 1. 原论文：它解决了什么问题

论文的贡献是把文献检索、全文获取、候选定位、多智能体关系抽取、评价、清洗和知识图谱串成可运行的开放框架。它不是一个训练出的单一模型，而是一套可替换 LLM、嵌入模型和数据源的工程系统。

## 1.1 论文信息

| 字段  | 内容                                                                                                                          |
|-----|-----------------------------------------------------------------------------------------------------------------------------|
| 题名  | ComProScanner: a multi-agent based framework for composition-property structured data extraction from scientific literature |
| 作者  | Aritra Roy, Enrico Grisan, John Buckeridge, Chiara Gattinoni                                                                |
| 期刊  | Digital Discovery, 2026, 5(4), 1794–1808                                                                                    |
| DOI | 10.1039/D5DD00521C                                                                                                          |
| 时间  | 2025-11-24 投稿; 2026-03-19 接收; 2026-03-25 首次在线                                                                               |
| 许可  | Open Access, CC BY                                                                                                          |

## 1.2 为什么需要它

材料论文中的性能数值常与化学式、变量取值、制备条件、测量条件分散在正文、表格和图中。传统命名实体识别能找到“材料名”和“数值”，却不一定能把二者正确配对；复杂固溶体如  $(1-x)A-xB$  还需要展开变量。论文因此把任务拆给多个专门 agent，并用工具调用处理检索、公式解析和图表。



原论文的核心不是某一个模型，而是端到端 workflow。

## 1.3 论文四阶段

| 阶段      | 原论文做法                                      | 在本项目中的对应位置                                              |
|---------|--------------------------------------------|---------------------------------------------------------|
| A 元数据检索 | Scopus Search API; 按时间、文献类型等过滤             | metadata_extractor/fetch_metadata.py、filter_metadata.py |
| B 文章收集  | Elsevier/Springer/Wiley TDM、IOP XML、本地 PDF | article_processors/*_processor.py                       |
| C 信息抽取  | RAG + 5 个专门 agent + 工具                     | extract_flow/main_extraction_flow.py、crews、tools        |
| D 后处理   | 语义/agent 评价、清洗、统计图、Neo4j                   | post_processing、data_visualizer.py、eval_visualizer.py   |

## 1.4 五个 agent 与工具

| 角色                          | 输入→输出                     | 边界                   |
|-----------------------------|---------------------------|----------------------|
| MaterialsDataIdentifierCrew | 候选文本/检索结果 → yes/no        | 决定是否继续，不能替代事实抽取      |
| CompositionExtractionCrew   | 相关文本 → 原始材料—性质事实          | 重科学语义与关系             |
| CompositionFormatCrew       | 原始事实 → 统一 JSON            | 重格式、单位、字段一致性         |
| SynthesisExtractionCrew     | 实验段落 → 方法、前驱体、步骤、表征       | Tc 当前批处理未启用          |
| SynthesisFormatCrew         | 制备原文 → 结构化 synthesis_data | 独立于 composition_data |
| RAGTool                     | 问题 → Chroma 相似片段          | 依赖已有向量库              |
| MaterialParserTool          | 变量化学式 → 展开组合              | 解决 x/y 等变量           |
| GraphExtractionTool         | 图像 → 图中数据                 | 需图像保存与 VLM 配置        |
| EquationTool                | 表达式 → 可计算/标准化结果           | 辅助复杂数值或公式            |

1.5 论文实验与结论的中文精读

数据集与任务

作者从 3,916 篇提及 d33 的 Elsevier 文献中选取 100 篇 (2019-01 至 2025-03) 做评测, 目标不仅是识别 d33, 而是提取材料组成—d33 的成对关系, 并可选抽取合成信息。

为什么选 PhysBERT

论文用 12 个材料学查询比较通用 all-mpnet-base-v2 与领域模型 PhysBERT。PhysBERT 对材料术语的语义邻近性更好, 因此用于 Chroma 向量库。它负责“找片段”, 不是最后生成数据库。

模型比较

多个闭源与开源 LLM 被放入同一 agent 框架比较。DeepSeek-V3-0324 在综合准确率、组成关系和合成抽取方面表现突出; Llama-3.3-70B 的归一化 P/R/F1 约为 0.80/0.81/0.80; Qwen 系列也有竞争力。结论是架构能换模型, 但模型选择依然显著影响结果。

数据库结果

100 篇样本中 BaTiO3 家族占比最高; 作者还统计前驱体与表征技术, 并构建 1,825 个节点的 Neo4j 图。一个重要发现是提取到的压电材料中超过 99% 不在 Materials Project 的压电数据库里, 说明文献抽取能补足数据库。

限制

LLM 非确定性、RAG 参数依任务调节、评价方法本身也会波动; 图像/OCR 与多性质联合抽取仍是未来方向。框架提供路径, 但不能替代人工 Gold 和质量控制。

版权说明: 本报告提供的是按章节忠实转述、方法解释与结果摘要, 不是对原论文逐句完整翻译。建议对照原文阅读: RS C <https://pubs.rsc.org/en/content/articlehtml/2026/dd/d5dd00521c>; DOI <https://doi.org/10.1039/D5DD00521C>。

2. 原始框架与当前项目：哪些没变，哪些改变了

当前仓库以原始 ComProScanner 为主体, Tc 工作通过属性 preset、候选构造、DOI 可选本地执行、超时与运行器加固来适配。仓库现在同时存在“已提交的冻结节点”和“工作区中继续实验的改动”, 报告据实际工作树描述。

| 维度         | 原论文/上游默认         | 当前 Tc 项目                               |
|------------|------------------|----------------------------------------|
| 性质         | 示例主要是压电系数 d33    | 居里/相变温度 Tc                             |
| 输入         | 出版社 TDM + 本地 PDF | 当前 100 篇主要走本地 pdfs/; 未来可接检索下载          |
| 候选         | 关键词门控 + RAG      | 高召回规则候选 + 前后句 + 完整表格 + PhysBERT 追加     |
| identifier | 通常同一 LLM 配置      | Qwen Flash 低成本 yes/no; 技术失败回退 DeepSeek |
| extractor  | 可配置多种 LLM        | DeepSeek / deepseek-v4-flash, 180 s    |
| DOI        | 强元数据中心           | 本地 PDF 可无 DOI; 使用 local-pdf/hash 身份    |
| 图像         | 工具与链路存在          | 当前 Tc runner 关闭 figure keywords 与保存    |
| 评价         | 语义与 agentic 评价   | 人工 Gold + 确定性 strict P/R/F1            |

2.1 Git 演进节点

| 提交      | 含义                                     |
|---------|----------------------------------------|
| c5470f4 | 加入 Curie temperature preset 的基线        |
| d1570b1 | 稳定本地 Tc: DOI 可选、180 s、NUL sanitation 等 |
| 0c5cb15 | Tc v2 管线定型                             |
| 5bec309 | 高召回预筛                                  |
| 3741241 | 提高 identifier recall                   |
| 3753149 | 拆分 Tc identifier 与 extractor prompt    |

注意：报告生成时工作树仍有未提交的 Hybrid+Qwen、候选上下文、文档和 runner 改动。因此 3753149 是最后一个已提交节点，不等于当前全部运行逻辑都已冻结。

3. 总体架构：四层如何配合

把所有代码看成四层，就不会被大量文件迷惑：核心库负责通用能力；preset 只描述“抽什么”；runner 描述“这次怎么跑”；outputs 保存不可替代的结果。




preset 被核心库消费，runner 负责一次实验的边界与落盘。

| 层         | 目录                        | 允许包含                            | 不应包含                      |
|-----------|---------------------------|---------------------------------|---------------------------|
| 核心库       | src/comproscanner         | 解析、候选、flow、clean/eval           | 具体论文编号、实验输出目录、密钥          |
| Preset    | src/comproscanner/presets | 科学范围、关键词、prompt 注释、示例           | API key、重试状态、benchmark 结果 |
| Runner    | scripts / examples        | 论文选择、模型、timeout、checkpoint、输出路径 | 通用科学逻辑的复制品                |
| Artifacts | outputs                   | prediction、Gold、metrics、报告      | 缓存、PDF 副本、日志、Chroma 临时库   |

4. 路径 A：你手动放入 PDF 后发生什么

当前 100 篇 Tc 主要使用这条路径。关键是区分长期输入 pdfs/、逐篇隔离副本 work/.../input、解析后的 CSV、向量库和最终 JSON。



runner 为每篇论文建立独立运行目录；单篇失败不会污染下一篇。

4.1 文件选择与编号

scripts/run\_tc\_hybrid\_qwen\_30.py 的 find\_pdf() 用文件名前缀 `^{paper_id}-` 匹配 pdfs/\*.pdf。每个编号必须唯一；同号两篇（例如曾出现的 68）需要明确策略，否则 runner 会报 multiple matches，避免静默把一篇覆盖另一篇。选中的原始 PDF 复制到 work/tc\_hybrid\_qwen\_001\_030/paper\_NNN/input/。

4.2 PDFsProcessor

ComProScanner.process\_articles(source\_list=['pdfs']) 把任务分派到 article\_processors/pdfs\_processor.py。它维护已处理记录、尝试从文件名/正文提取 DOI、生成无 DOI 的 local document id、调用 PDFToMarkdownText、记录失败 PDF，并将每篇文章写成规范表格。

4.3 Docling 解析

utils/pdf\_to\_markdown\_text.py 配置 Docling，把版面转换为 Markdown 式文本与表格，清理软连字符、控制字符等，按 section 写入 DataFrame。当前 NUL 修复保证读取 CSV 时先清除 \x00，防止正文在中途被截断。Docling 能恢复文本/表格，但扫描件质量、双栏顺序、公式和图中数值仍可能丢失。

4.4 规范化章节 CSV

产物位于 work/.../results/extracted\_data/magnetic/\*.csv。典型字段包含 doi、title/metadata、abstract、introduction、experimental/methods、results\_discussion、conclusion、tables、is\_property\_mentioned 等。后续 agent 通常不再直接打开 PDF，而是读取这张章节表。

4.5 原始文本恢复

当前 runner 还有 recover\_raw\_text\_candidate(): 若结构化章节没有把论文判为相关，则用 PyMuPDF 从 PDF 全文取纯文本；只有确定性 Tc 关键词/正则命中时才把全文写入 results\_discussion 并建向量库。它弥补章节解析漏检，但会增加上下文长度和噪声。

4.6 输出落点

| 对象      | 路径示例                                             | 是否最终保留       |
|---------|--------------------------------------------------|--------------|
| 原始输入    | pdfs/1-title.pdf                                 | 是；作为可复现语料    |
| 逐篇副本    | work/.../paper_001/input/                        | 否；可再生        |
| 章节 CSV  | work/.../results/extracted_data/magnetic/*.csv   | 调试时有价值，通常可再生 |
| Chroma  | work/.../paper_001/db/                           | 否；可再建        |
| 单篇结果    | outputs/.../papers/paper_001.json                | 是            |
| 合并结果    | outputs/.../predictions_001_100.json             | 是            |
| 人工 Gold | outputs/tc_final_001_030/gold_facts_001_030.json | 是，不可用预测替代    |
| 指标      | outputs/.../strict_metrics_001_030.json          | 是，需带口径       |

5. 路径 B：API 发现与下载 PDF

项目要获取“与现有 100 篇类似”的新论文，应把“发现元数据”和“合法获得全文”拆成两个问题。Semantic Scholar/Scopus/Crossref 帮你找文献；Unpaywall、openAccessPdf 或出版社 TDM 决定能否取得全文。



下载完成后与手动 PDF 汇入同一 PDFsProcessor 主干。

5.1 推荐的发现流程

- 以现有 100 篇 DOI/标题作为正样本种子，查询相似论文、参考文献和被引网络。
- 限制年份、文献类型和主题：优先研究论文，排除 review、conference、correction。

- 保存 candidate\_manifest.csv/json: paper\_id、title、doi、year、journal、authors、source、OA 状态、PDF URL、审核状态。
- 先人工批准候选，再下载；不要让“检索命中”自动等价于“纳入语料”。
- 下载后验证 HTTP 类型与文件头 %PDF，计算 SHA-256，以 DOI + hash 双重去重，再重命名为 101-title.pdf 等稳定编号。

## 5.2 API 各自负责什么

| 服务               | 主要作用                           | 不能保证                   |
|------------------|--------------------------------|------------------------|
| Semantic Scholar | 相似推荐、引用网络、元数据、部分 openAccessPdf | 不能绕过付费墙；key 主要提升额度和稳定性 |
| Scopus           | 高质量检索、主题与文献类型过滤                | 全文下载权取决于订阅与 TDM 条款     |
| Crossref         | DOI/标题/期刊元数据核验                 | 通常不是全文 PDF 仓库          |
| Unpaywall        | 按 DOI 找合法开放获取位置                | 闭源论文可能没有 OA 链接         |
| 出版社 TDM          | 在许可和机构权限下取得结构化全文/PDF           | 每家 API、配额、许可不同         |

## 5.3 无 Semantic Scholar key 时

多数端点仍可匿名调用，但速率较低。应限制为约 1 request/s、指数退避、缓存响应、支持断点续跑。一个 API key 不会让单个 PDF 网络传输本质变快，也不会增加付费文献访问权；它主要减少限流和失败。

# 6. DOI 在项目中的真实作用

DOI 很重要，但它不是“允许抽取的门票”。本地文件可用稳定哈希身份继续运行；同时必须防止参考文献 DOI 被错当作文本 DOI。

| 阶段         | DOI 的作用             | 缺失时策略                   |
|------------|---------------------|-------------------------|
| 元数据        | 关联标题、期刊、作者、年份       | 从文件名/首页/清单补充；未知字段保留空    |
| 去重         | 同一文章跨来源合并           | 用 PDF SHA-256 + 标题规范化   |
| 向量库        | 转义后作为 db_name       | local-pdf/ 同样可转义命名      |
| checkpoint | checked_dois 避免重复处理 | 改为 document_id 语义更准确    |
| 最终 JSON    | 稳定主键与可追溯引用          | 保留 local id，并标记 DOI 待核验 |

已知风险：从全文正则抓 DOI 时可能抓到参考文献 DOI。Paper 11 曾出现这种情形。更稳妥的优先级应为：人工 manifest DOI > 出版商元数据 > 首页标题/DOI 区域 > Crossref 标题核验 > 全文正则；低置信度 DOI 不应覆盖已有 document\_id。

# 7. 候选文本如何产生，以及为何会丢上下文

LLM 并非总是读取整篇文章。候选构造决定了它“看得见什么”，因此 Recall 的上限常在 LLM 调用之前已经确定。

## 7.1 SectionProcessor 的规则候选

- 把章节中的 Markdown 表格与普通文本分开；表格作为整体保存，避免逐句破坏行列关系。
- 文本按句切分；保留包含数字或连续大写字母的句子，因为材料式、温度和缩写常满足这个条件。
- 当前最小改动加入命中句的前一句与后一句，使材料名在前句、数值在后句时仍能配对。
- 结果/讨论中的完整相关表格被纳入，以减少表格事实漏失。

- 各章节再按固定标签拼接为 rule\_candidate。

## 7.2 论文级预筛

PDF 解析阶段用 preset 的 exact/substrings/regex 信号判断是否出现 Tc 相关表达。高召回策略宁可让背景材料进入，也不应只保留“本文研究材料”。这是当前目标由“研究对象数据库”转为“论文中正确出现的材料—Tc 对”的关键改变。

## 7.3 Hybrid PhysBERT

candidate\_context.py 先保留完整 rule\_candidate，再按多个 Tc 查询从 Chroma/PhysBERT 取 top-k 片段，规范化空白后去重并追加。若向量库不存在、依赖失败或查询异常，返回原规则候选。这样 RAG 只能提高覆盖，不能删掉确定性规则已经找到的证据。

## 7.4 上下文仍可能缺失的四处

| 漏失点    | 例子                            | 诊断方法                         |
|--------|-------------------------------|------------------------------|
| PDF 解析 | 双栏错序、扫描页、公式/表格损坏              | 对照原 PDF 与章节 CSV              |
| 章节归类   | 关键句被放进 reference/unknown 或未写入 | 搜索 raw text 与 CSV 各列         |
| 规则候选   | 材料与温度隔了超过 $\pm 1$ 句           | 搜索 candidate text 是否含证据      |
| LLM 抽取 | 证据已在 candidate 但模型未输出         | 保存 prompt 输入并与 prediction 比较 |

# 8. Tc 抽取的实际模型链路

当前 Hybrid+Qwen runner  
把“有没有可抽取事实”和“抽取事实本身”拆给不同模型，以降低成本；任何模型输出都必须经过 JSON 解析、状态记录和人工 Gold 评价。

规则+RAG候选 → Qwen yes/no → DeepSeek 原始抽取 → 格式化 → paper\_NNN.json

Qwen 技术错误时可回退 DeepSeek identifier；科学空结果不因质量差而自动重试。

| 配置         | 当前值                                                        | 位置                                                          |
|------------|------------------------------------------------------------|-------------------------------------------------------------|
| 属性         | Curie temperature / transition temperature (按 preset 科学边界) | presets/curie_temperature.py                                |
| Identifier | Qwen qwen-flash (DashScope OpenAI-compatible)              | preset extraction_kwargs                                    |
| Extractor  | DeepSeek / deepseek/deepseek-v4-flash                      | runner                                                      |
| Timeout    | 180 s / paper extraction flow                              | runner → ComProScanner.extract...                           |
| 候选模式       | hybrid；规则主干 + PhysBERT 追加                                  | candidate_context.py                                        |
| 图像         | 本轮关闭                                                       | main/additional_figure_keywords<br>空；is_save_relevant=False |
| 重试         | 默认每篇一次；技术失败记录，不因空结果追求重跑                                    | runner                                                      |

## 8.1 Tc 的科学边界

“Curie temperature”通常指铁电—顺电或铁磁—顺磁相变温度；论文也可能写 dielectric anomaly、ferroelectric transition、magnetic transition、T<sub>C</sub> 等。当前 Gold 目标已允许论文中的背景材料，只要材料与温度有明确对应。烧结温度、退火温度、测量温度和只表达上/下限而无可归属材料的数值不应误作 Tc。

8.2 状态语义

| 状态                       | 含义                 | 是否表示程序失败        |
|--------------------------|--------------------|-----------------|
| COMPLETED                | 成功完成且至少一个材料—Tc 值   | 否               |
| EMPTY_RESULT             | flow 完成但无值；可能是真空结果 | 否               |
| PREFILTER_REJECTED       | 确定性门控未发现相关信号       | 否，但应抽样审计 Recall |
| PROCESSING_ERROR         | PDF/CSV/解析阶段异常     | 是               |
| EXTRACTION_ERROR/TIMEOUT | LLM/flow 阶段异常或超时   | 是               |
| MISSING_PDF              | 编号没有唯一文件           | 是，输入问题          |

9. JSON、Gold、评分与 “数据库”

项目当前最可信的数据库形态是可审计 JSON，而不是必须写入 MySQL。MySQL、CSV、Chroma 和 Neo4j 各自解决不同问题，不能混称为同一个数据库。

9.1 单篇 prediction 结构

runner外层记录  
paper\_id、filename、pdf\_path、status、runtime\_seconds、attempt\_count、error、pipeline\_report；output  
内按 DOI/local id 保存 composition\_data、可选 synthesis\_data 与 article\_metadata。composition\_data  
中核心是 compositions\_property\_values、property\_unit、family。

```
{
  "paper_id": 53, "status": "COMPLETED",
  "output": {"local-pdf/...": {
    "composition_data": {
      "compositions_property_values": {"BFS-BT-Mn-0": 624},
      "property_unit": "°C"
    }, "article_metadata": {...}
  }}
}
```

9.2 四种存储后端

| 存储     | 用途                              | 当前 Tc 是否主用           |
|--------|---------------------------------|----------------------|
| CSV    | 规范化文章章节；也可批量落表                  | 是（中间层）               |
| JSON   | 模型结果、Gold、metrics，可 git/diff/审计 | 是（最终资产）              |
| MySQL  | 大批结构化章节/结果的关系型持久化               | 代码存在，当前 runner 默认未启用 |
| Chroma | PhysBERT 向量索引，仅供 RAG 查询         | hybrid 可用，但属于可再生索引   |
| Neo4j  | 材料—性质—文献关系可视化/查询                | 代码存在，当前 Tc 最终库尚未正式构建 |

9.3 Gold 与指标

Gold 必须由人基于原文接受；预测不能反向自动成为 Gold。最小 Gold 可只记录 paper\_id、material、tc\_value、tc\_unit，并建议额外保留 page/evidence、fact\_role、transition\_type、strict\_scoring，便于争议复核。匹配时需处理化学式别名、单位换算、范围/不等式和容差。

| 指标        | 公式             | 当前解释             |
|-----------|----------------|------------------|
| Precision | TP / (TP + FP) | 输出的材料—Tc 中有多少是真的 |

| 指标      | 公式                           | 当前解释                              |
|---------|------------------------------|-----------------------------------|
| Recall  | $TP / (TP + FN)$             | Gold 中有多少被找回来                     |
| F1      | $2PR / (P + R)$              | 精确率与召回率的调和平均                      |
| 当前 30 篇 | $P=0.977, R=0.913, F1=0.944$ | 46 条 strict Gold; 42 TP、1 FP、4 FN |

## 10. 当前 30 篇的错误分析

这些错误展示了三类问题：证据没进入候选、证据进入但模型漏抽、模型把模糊陈述变成了精确值。优化时必须先判断错误发生在哪一层。

| 论文       | 现象                                                                                            | 所在层/含义                              |
|----------|-----------------------------------------------------------------------------------------------|-------------------------------------|
| Paper 6  | 预测 $BaTiO_3 = 130\text{ }^{\circ}\text{C}$ ；原文仅把 $<200\text{ }^{\circ}\text{C}$ 的峰与 BTO Tc 联系 | 1 个 FP；模型将含糊背景知识具体化，不是读图所得          |
| Paper 11 | Gold 的 $BaTiO_3 = 120\text{ }^{\circ}\text{C}$ 未输出                                            | 正文/章节上游缺失；还暴露参考文献 DOI 误识别风险         |
| Paper 17 | $BiFeO_3 = 1103\text{ K}$ 未输出                                                                 | 明确背景事实，但未进入可见上下文                    |
| Paper 25 | $650\text{ }^{\circ}\text{C}$ 与掺 La 后 $227\text{ }^{\circ}\text{C}$ 均未输出                      | 证据已进入 candidate，属于 extractor recall |
| Paper 30 | $>\text{约}580\text{ }^{\circ}\text{C}$                                                        | 范围/不等式事实；保留 Gold 但暂作 non-strict     |

### 10.1 调试顺序

- 先看原 PDF：Gold 事实是否真实存在、材料和温度是否明确对应。
- 再看 raw text：解析器是否读到该句/表格。
- 再看章节 CSV：是否被归类 and 保存。
- 再看 rule/hybrid candidate：是否到达模型输入。
- 最后看 identifier/extractor 原始响应：是 gate 拒绝还是抽取遗漏。
- 只有定位层级后再改代码；否则更换模型可能掩盖解析问题。

## 11. 项目目录总览

下面按维护者视角解释目录。并非所有目录都同等重要：先掌握 src/comproscanner、presets、scripts、pdfs、work、outputs 六处即可运行和诊断。

```
ComProScanner/  
├─ src/comproscanner/ 核心库  
│ └─ article_processors/ 全文入口适配  
│ └─ metadata_extractor/ 检索与元数据过滤  
│ └─ extract_flow/ CrewAI 流程、agent、工具  
│ └─ post_processing/ 清洗、评价、可视化/知识图谱  
│ └─ presets/ 性质适配层（当前含 Tc）  
│ └─ utils/ 解析、候选、数据库、嵌入、路径与日志  
├─ scripts/ 可恢复 benchmark/批处理 runner  
├─ examples/ 用户调用示例  
├─ tests/ 回归与性质特定测试  
├─ pdfs/ 长期 PDF 输入  
├─ work/ 逐篇运行中间物（可再生）  
├─ outputs/ prediction、Gold、metrics、报告  
├─ docs/ MkDocs 文档  
└─ tmp/results/db/logs/ 临时或历史产物
```

## 12. 逐文件职责：公共入口、处理器与元数据

本节按代码文件解释“谁调用谁”。文件很多，但大多数都有清晰单一职责；带 \* 的文件对当前 Tc 路径最关键。

| 文件                                       | 职责与关键调用                                                                                                                                    |
|------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------|
| src/comproscanner/_init_.py              | 对外 facade：导出 ComProScanner、preset、评价和可视化函数，减少用户对内部路径的依赖。                                                                                   |
| src/comproscanner/comproscanner.py *     | 总调度器。collect_metadata → 元数据；process_articles → 按 source 分派处理器；extract_composition_property_data → DataExtractionFlow；clean/evaluate → 后处理。 |
| article_processors/pdfs_processor.py *   | 本地 PDF 批处理、DOI/本地 id、失败记录、Docling 转换、processed checkpoint、CSV/SQL 写入。                                                                      |
| article_processors/elsevier_processor.py | 用 Elsevier TDM/全文响应解析章节、表格、图与元数据，写统一结构。                                                                                                    |
| article_processors/springer_processor.py | Springer Nature 全文接口与 XML/文档结构适配。                                                                                                          |
| article_processors/wiley_processor.py    | Wiley TDM/PDF 获取与解析适配。                                                                                                                     |
| article_processors/iop_processor.py      | 处理本地/批量 IOP XML，映射为统一章节。                                                                                                                   |
| metadata_extractor/fetch_metadata.py     | 构造 Scopus 查询、分页请求、保存原始元数据。                                                                                                                 |
| metadata_extractor/filter_metadata.py    | 按类型、年份、重复项、已有记录等过滤，形成可处理清单。                                                                                                                |

## 13. 逐文件职责：抽取 flow、crews 与工具

DataExtractionFlow 是执行状态机；crew 的 Python 文件装配 agent/task，YAML 保存角色说明和任务 prompt。

| 文件                                                   | 职责                                                                                           |
|------------------------------------------------------|----------------------------------------------------------------------------------------------|
| extract_flow/main_extraction_flow.py *               | MaterialsState + CrewAI Flow；载入论文候选、可选图像检查、identifier 路由、组成抽取、格式化、可选合成抽取、最终保存；记录 flow error。 |
| crews/materials_data_identifier_crew/*.py,yaml *     | 判断候选是否包含可抽取材料—性质关系；当前支持独立 identifier model/base_url/key。                                     |
| crews/composition_crew/composition_extraction_crew/* | 保留材料与 Tc 的科学对应、变量组成、条件与单位；tasks.yaml 承载主抽取约束。                                                |
| crews/composition_crew/composition_format_crew/*     | 把原始自然语言结果转换为 schema 一致 JSON，处理 property_unit/family 等。                                       |
| crews/synthesis_crew/synthesis_extraction_crew/*     | 从实验段抽取方法、前驱体、步骤、表征；Tc 当前未启用。                                                                 |
| crews/synthesis_crew/synthesis_format_crew/*         | 规范化 synthesis_data。                                                                          |
| tools/rag_tool.py                                    | 面向 agent 的 Chroma 查询工具，返回与 query 最相似的文档块。                                                    |
| tools/material_parser_tool.py                        | 解析变量化学式和取值，生成具体材料表达。                                                                         |
| tools/equation_tool.py                               | 计算或规范化数学表达式，防止 agent 手算错误。                                                                   |
| tools/graph_extractor_tool.py                        | 调用视觉模型读取已提取的相关图；必须有图像文件与 VLM 配置。                                                             |

## 14. 逐文件职责：utils 与配置

utils 是数据路径中最容易被忽视却最决定召回率的一层。

| 文件                              | 职责                                                                                       |
|---------------------------------|------------------------------------------------------------------------------------------|
| utils/pdf_to_markdown_text.py * | Docling converter、Markdown/表格、caption、图像保存、文本清理、章节写表、property signal 匹配。                 |
| utils/data_preparator.py *      | read_csv_sanitizing_nul；SectionProcessor 分表/句、数字/大写筛选与前后句；MatPropDataPreparator 读取未处理论文。 |

| 文件                                 | 职责                                                                     |
|------------------------------------|------------------------------------------------------------------------|
| utils/candidate_context.py *       | rule candidate 与 PhysBERT chunks 合并、规范化去重、hybrid fail-open。            |
| utils/database_manager.py          | MySQL 建表/追加、CSV 分批写入、Chroma create/query/exists。                       |
| utils/embeddings.py                | 统一 HuggingFace、sentence-transformers、OpenAI embeddings；按模型名选择 backend。 |
| utils/get_paper_data.py            | 把文章表中 metadata/section/figure 信息整理为 extraction flow 可消费对象。             |
| utils/figure_extractor.py          | 从出版商内容/文件中保存匹配 caption 的图像，建立相关图目录。                                    |
| utils/save_results.py              | JSON 等结果的安全保存/合并辅助。                                                    |
| utils/common_functions.py          | 跨模块通用工具。                                                               |
| utils/prepare_iop_files.py         | IOP 批量文件预处理。                                                           |
| utils/error_handler.py             | 错误包装/记录策略。                                                             |
| utils/logger.py                    | 统一日志。                                                                  |
| utils/configs/paths_config.py      | 默认目录结构。                                                                |
| utils/configs/llm_config.py        | 模型/provider 默认配置与环境变量读取。                                               |
| utils/configs/rag_config.py        | chunk size/overlap/top-k、db path、embedding model。                      |
| utils/configs/article_keywords.py  | 通用文章/章节关键词。                                                            |
| utils/configs/base_urls.py         | 出版社/模型接口基础 URL。                                                        |
| utils/configs/database_config.py   | 关系数据库配置。                                                               |
| utils/configs/custom_dictionary.py | 材料/文本规范化相关自定义词典。                                                       |

## 15. 逐文件职责：preset、后处理、runner 与测试

这部分决定项目是否可扩展、是否可验证。

| 文件/组                                                    | 职责                                                                                                      |
|---------------------------------------------------------|---------------------------------------------------------------------------------------------------------|
| presets/base.py                                         | PropertyExtractionPreset 数据结构与 validate/to_runtime_dict；规定属性适配的边界。                                      |
| presets/registry.py                                     | 按稳定名称注册、获取、列出 preset。                                                                                   |
| presets/curie_temperature.py *                          | Tc 关键词/正则、candidate patterns、identifier inclusion/exclusion、extract/format notes、示例、Qwen identifier 配置。 |
| post_processing/data_cleaner.py                         | 材料式括号、缩写、元素、算术/分数组成等清洗。                                                                                 |
| post_processing/evaluation/semantic_evaluator.py        | 按语义相似与规范化规则对测试结果与真值比较。                                                                                  |
| post_processing/evaluation/eval_flow/*                  | 用评价 agent 检查组成与合成结果，形成 agentic metrics。                                                                 |
| post_processing/visualization/create_knowledge_graph.py | 把结果变换为 Neo4j 节点/关系。                                                                                     |
| .../data_distribution_visualizers.py                    | 材料家族、前驱体、表征等分布图。                                                                                        |
| .../eval_plot_visualizers.py                            | 单/多模型评价可视化。                                                                                             |
| data_visualizer.py / eval_visualizer.py                 | 对外可视化 facade。                                                                                           |
| scripts/run_tc_hybrid_qwen_30.py *                      | 实际 Paper 1-100 可恢复 runner：唯一映射、逐篇隔离、一次调用、raw-text recovery、原子 JSON、resume。                              |
| scripts/run_tc_dev_benchmark.py                         | 冻结 Dev benchmark 运行。                                                                                    |
| scripts/run_tc_dev_recovery.py                          | 特定 Dev 恢复场景；不应成为通用生产分支。                                                                                 |
| examples/extract_curie_temperature.py                   | 用户级 Tc 调用示例。                                                                                            |
| tests/test_curie_temperature_preset.py                  | preset 合法性和配置边界。                                                                                        |
| tests/test_tc_*                                         | 高召回预筛、identifier 语义、prompt 分离、recovery 回归。                                                              |

| 文件/组                                          | 职责                          |
|-----------------------------------------------|-----------------------------|
| tests/test_candidate_context.py               | hybrid 合并、去重、缺库/失败回退。       |
| tests/test_article_processors/*, test_utils/* | 各数据源、PDF、候选、数据库、嵌入与保存的单元回归。 |

## 16. 一次运行的调用栈与伪代码

把路径和类名连起来后，可以用下列调用栈定位任何问题。

```
run_tc_hybrid_qwen_30.main()
└─ run_paper(id, pdf)
  └─ get_curie_temperature_preset()
    └─ ComProScanner.process_articles()
      └─ PDFsProcessor.process_pdfs()
        └─ PDFToMarkdownText.convert_to_markdown()
          └─ clean_text / append_section_to_df
            └─ CSVDatabaseManager.write_to_csv()
              └─ recover_raw_text_candidate() [必要时]
                └─ VectorDatabaseManager.create_database()
                  └─ ComProScanner.extract_composition_property_data()
                    └─ MatPropDataPreparator.get_unprocessed_data()
                      └─ build_hybrid_candidate_context()
                        └─ DataExtractionFlow.kickoff()
                          └─ identify_materials_data_presence()
                            └─ extract_composition_property_data()
                              └─ extract_final_composition_property_data()
                                └─ finalize_results()
  最终: paper_NNN.json → predictions_001_100.json
```

### 16.1 为什么单篇失败不停止

run\_paper 用 try/except/finally 包裹 processing 和 extraction，并把 stage、error、traceback、runtime 写入单篇记录；main 每完成一篇就原子写 JSON，再继续下一篇。重启时加载 papers/paper\_\*.json 并 SKIPPED\_EXISTING，只有 --force 才重发。

## 17. 图片、表格与视觉模型：代码存在 ≠ 当前启用

仓库有 figure extractor 与 GraphExtractionTool，原论文也把图表抽取作为工具链的一部分。但当前 Tc runner 把主/附加 figure keywords 设为空，并设置 is\_save\_relevant=False，所以 DeepSeek/Qwen 收到的是文本候选，不是 PDF 页面图像。

| 要启用图像 Tc | 需要的最小工作                                                                                           |
|----------|---------------------------------------------------------------------------------------------------|
| 1 图像发现   | 给 main_figure_keywords/additional_figure_keywords 配置 Tc、Curie、transition、dielectric 等 caption 信号。 |
| 2 保存     | 启用相关图保存，确保 related_figures_base_path 按 paper/document id 对齐。                                      |
| 3 VLM    | 配置支持图像的模型/provider/key；GraphExtractionTool 读取图而非文本 LLM 猜测。                                        |
| 4 schema | 保存 figure/page、曲线/图例、估读值、单位、不确定性和 evidence_type=figure。                                           |
| 5 评价     | 图读数应有容差并与正文精确值分开；人工 Gold 标注来源。                                                                    |

不要直接把视觉估读与正文精确数值混在同一严格评分里。先建立单独的小型 figure-Gold，再开启图像路径。

## 18. 增加 Ms 等新性质的最小改动方案

正确扩展方式是增加 preset，而不是复制 PDF 解析器或修改 Tc prompt。只有通用 schema 无法表达新科学信息时，才改核心结构。

## 18.1 Ms preset 应包含

- 稳定名称 saturation\_magnetization; main\_property\_keyword 用于目录/存储。
- 高召回信号: saturation magnetization、M\_s、Ms、emu/g、A·m<sup>2</sup>/kg 等, 同时排除 mass spectrometry 等歧义。
- identifier 定义: 材料与 Ms 数值必须可配对; 背景材料允许与否需在 Gold 规范先确定。
- extractor 注释: 区分 Ms、Mr、Mmax; 保留测量温度、磁场、单位、样品形态和不等式/范围。
- 固定/变量组成示例; formatter 示例; 代表性正例、负例、边界例测试。

## 18.2 何时需要扩 schema

如果只需要 material → numeric value + unit, 通用 compositions\_property\_values 可以复用。若要做可信磁学数据库, 建议新增 measurement\_temperature、applied\_field、sample\_form、value\_operator、value\_min/max、uncertainty、evidence、page。否则同一材料在不同条件下的 Ms 会被错误折叠。



性质扩展首先是评价设计, 其次才是 prompt。

## 19. 当前架构中不干净或不合理的地方

以下不是要求立刻重构, 而是按收益/风险排序的维护清单。当前最重要的是冻结可复现路径, 而不是在批次运行中大改核心。

| 优先级 | 问题                                        | 建议                                                       |
|-----|-------------------------------------------|----------------------------------------------------------|
| P0  | 密钥曾在聊天中暴露                                 | 立即在供应商侧轮换; .env 仅本机保存; 日志与报告永不写 key。                     |
| P0  | 当前 Hybrid 逻辑仍有未提交工作树改动                    | 100 篇完成且审核后跑相关测试, 形成单一干净 freeze commit。                  |
| P1  | 输出目录仍叫 tc_hybrid_qwen_001_030, 但已承载 1–100 | 新批次改名 tc_hybrid_qwen_001_100; 保留旧路径映射清单。                 |
| P1  | runner 中 raw-text recovery 是实验性旁路         | 抽象为可配置 core fallback, 并为解析漏失/不命中分别测试。                    |
| P1  | DOI 全文正则可能抓参考文献                           | 增加来源优先级、标题核验、confidence 与 doi_status。                    |
| P1  | JSON map 难表示同材料多条件/范围                     | 迁移到 fact list schema; 每条事实有 evidence/condition/operator。 |
| P2  | 候选与模型原始输入未形成稳定最终审计包                       | 每篇可选保存 candidate manifest 与响应摘要 (不含 key)。                |
| P2  | results/work/outputs 历史命名混杂               | 明确 retention policy: outputs 仅最终; work 可清理; pdfs 只放语料。   |
| P2  | 图像链路虽存在但未纳入 Tc QA                         | 单独建立 10–20 个图读数 Gold, 不直接并入文本指标。                         |

## 20. 安全、成本与可复现运行规范

模型调用会把候选正文发送给第三方; 运行前必须明确授权、模型、范围和次数。API key 只从环境变量读取。

- 输入授权: 记录允许发送的 paper ids、PDF 来源、provider/model、每篇次数。
- 密钥: .env 加入 .gitignore; 出现于聊天/日志后视为泄露并轮换。
- 断点: 每篇 JSON 原子写入; 启动时跳过已有记录; 失败状态可审计。
- 成本: identifier 用低价模型, extractor 用更强模型; 先预筛再调用, 但门控要抽样评估 Recall。
- 复现: 保存 commit hash、preset 名称/版本、模型字符串、timeout、候选模式、运行时间和 Gold 版本。
- 数据合规: 只通过机构许可、出版社 TDM 或合法 OA URL 下载全文; 元数据 API 不等于全文许可。

## 21. 你可以亲自执行的操作手册

以下是理解项目后最常用的只读检查与运行入口。命令默认在 F:\Python\_Project\ComProScanner 执行。

### 21.1 检查输入映射

```
python scripts/run_tc_hybrid_qwen_30.py --validate-only
```

### 21.2 运行指定论文

```
python scripts/run_tc_hybrid_qwen_30.py --paper-ids 31 32 33
```

### 21.3 恢复批次

```
python scripts/run_tc_hybrid_qwen_30.py
```

已有 paper\_NNN.json 会跳过。不要随意使用 --force；它会重新发送并覆盖该篇结果。

### 21.4 查看进度

```
Get-Childitem outputs/tc_hybrid_qwen_001_030/papers/paper_*.json | Measure-Object
```

### 21.5 调试一条 FN

依次检查 pdfs/原文 → work/.../\*.csv → 候选文本/向量 chunks → paper\_NNN.json/pipeline\_report。先确认事实在哪层消失，再决定改解析、候选还是 prompt。

## 22. 明日汇报可直接使用的 10 分钟提纲

建议把重点放在“为什么做、如何做、做到什么、下一步怎么验证”，而不是逐文件念目录。

| 时间       | 讲什么       | 一句话重点                                                                      |
|----------|-----------|----------------------------------------------------------------------------|
| 0–1 min  | 问题        | 材料性质散落在论文文本/表/图中，手工整理慢且关系容易配错。                                             |
| 1–3 min  | 原论文       | ComProScanner 用检索、全文获取、RAG、多 agent、清洗评价构成端到端框架。                            |
| 3–5 min  | 我们的 Tc 工作 | 不复制主框架，用 preset、高召回候选、DOI 可选、NUL 修复和可恢复 runner 适配 Tc。                      |
| 5–7 min  | 数据流       | PDF → Docling/章节 CSV → 规则+PhysBERT 候选 → Qwen 判定 → DeepSeek 抽取 → JSON/Gold。 |
| 7–8 min  | 结果        | 前30篇 strict: P=0.977, R=0.913, F1=0.944；主要瓶颈在上游候选和少量幻觉。                    |
| 8–9 min  | 现状边界      | 文本链路已可运行；图像链路存在但当前未启用；31–100 尚需完整 Gold 才能评价。                               |
| 9–10 min | 未来        | 先冻结 100 篇可复现版本，再做 API 发现/合法 OA 下载、fact-list schema、Ms preset 与独立图像 Gold。   |

## 23. 术语表

这些词在项目讨论中经常混用，建议按下列定义统一。

| 术语     | 本项目中的准确含义                                           |
|--------|-----------------------------------------------------|
| Tc     | 居里/相关铁电或磁性相变温度，具体纳入边界由 preset 与 Gold 规范决定。          |
| Preset | 一组属性科学配置：关键词、候选信号、identifier/extractor 注释、示例和运行默认项。 |

| 术语         | 本项目中的准确含义                             |
|------------|---------------------------------------|
| Prefilter  | LLM 之前的确定性论文相关性门控。                    |
| Candidate  | 真正送给 identifier/extractor 的文本；通常小于全文。 |
| RAG        | 从向量库检索相关片段并补充上下文；不等于生成最终事实。           |
| PhysBERT   | 材料科学领域 embedding 模型，用来把文本转为向量。        |
| Chroma     | 存储和查询向量/文本块的本地数据库。                    |
| Gold       | 经人工查原文确认的参考事实集合。                      |
| Prediction | 模型输出；未审核前不能视为数据库真值。                   |
| COMPLETED  | 程序成功且输出了至少一个值；不保证每条都正确或没有遗漏。          |
| DOI        | 论文持久标识符；用于关联与去重，但本地无 DOI 文件仍可抽取。      |

## 24. 参考资料与本地证据

报告中的工程描述来自当前工作树与产物快照；论文描述来自正式 RSC 页面与 arXiv 预印本。

- [1] Roy, A.; Grisan, E.; Buckeridge, J.; Gattinoni, C. ComProScanner. Digital Discovery 2026, 5, 1794–1808. DOI: 10.1039/D5DD00521C.
- [2] RSC HTML: <https://pubs.rsc.org/en/content/articlehtml/2026/dd/d5dd00521c>
- [3] Official repository: <https://github.com/slimeslab/ComProScanner>
- [4] Official documentation: <https://slimeslab.github.io/ComProScanner/>
- [5] arXiv preprint: <https://arxiv.org/abs/2510.20362>
- [6] 本地架构说明: docs/architecture.md; docs/about/project-structure.md; docs/usage/\*。
- [7] 当前严格指标: outputs/tc\_hybrid\_qwen\_001\_030/strict\_metrics\_001\_030.json。
- [8] 当前人工 Gold: outputs/tc\_final\_001\_030/gold\_facts\_001\_030.json。
- [9] 当前 runner: scripts/run\_tc\_hybrid\_qwen\_30.py。

最后结论：这个项目已经具备可解释、可恢复、可扩展的文本抽取主干，但“链路存在”不等于“所有能力已启用”，也不等于“数据库无需人工校验”。目前最合理的工程方向是：冻结当前 100 篇文本管线与审计资产；修正 DOI/输出命名/schema；再以独立 Gold 推进 Ms 和图像抽取。